

## AULA 03 - MLCB

### PRÉ-PROCESSAMENTO E AVALIAÇÃO AVANÇADA DE MODELOS

O objetivo desta aula é dar ao nosso modelo de NLU a capacidade de ignorar ruídos de linguagem e ensinar como medir a eficiência real do chatbot usando métricas profissionais.

#### Pré-processamento de Texto: Limpar ruído

##### Stopwords

Quando um usuário envia uma mensagem para o chatbot, como:

***"Eu preciso urgentemente de uma segunda via do meu boleto, por favor"***

As palavras *"Eu"*, *"de"*, *"uma"*, *"do"*, *"meu"*, *"por"*, *"favor"* são usadas apenas para dar coesão gramatical. Em inteligência artificial aplicada a texto, chamamos essas palavras genéricas e de altíssima frequência de **Stopwords**.

Se mantivermos as Stopwords, o modelo corre o risco de achar que a palavra *"de"* é o termo mais importante da frase só porque ela aparece em quase todas as intenções.

- **Solução: Remoção de Stopwords.** Filtramos o texto para manter apenas as palavras que carregam intenção semântica real: ["segunda", "via", "boleto"].

#### O Poder dos N-Grams: Entendendo Expressões

Analisar palavras isoladas (*Unigramas*) às vezes faz o modelo perder o sentido da mensagem.

- A palavra **"segunda"** isolada pode ser o dia da semana (*segunda-feira*).
- A palavra **"via"** isolada pode ser uma rua ou caminho.
- No entanto, o par **"segunda via"** (*Bigrama*) refere-se unicamente a um documento!

A configuração `gram_range=(1, 2)` no `TfidfVectorizer` instrui o modelo a analisar palavras individuais e pares de palavras consecutivas ao mesmo tempo.

## Acurácia

A Acurácia é a métrica mais intuitiva de todas. Ela responde a uma pergunta básica: "De todas as tentativas, qual foi a porcentagem total de acertos do modelo?"

A fórmula matemática simples é:

$$\text{Acurácia} = \frac{\text{Total de Acertos}}{\text{Total de Mensagens Avaliadas}}$$

### Exemplo:

Se o seu teste possui **10 mensagens** de usuários e o modelo acerta a intenção de **8 delas**, a acurácia é:

$$\frac{8}{10} = 0,80 \quad (\text{ou } 80\% \text{ de acurácia})$$

### A Armadilha da Acurácia (Por que não confiar apenas nela?)

Embora seja fácil de entender, a acurácia pode mentir se o seu conjunto de dados estiver desbalanceado (ou seja, quando você tem muito mais frases de uma intenção do que de outra).

### Métricas Avançadas de Avaliação

A acurácia mede a porcentagem de acertos gerais, mas a acurácia pode ser extremamente enganosa em bases desbalanceadas.

### Exemplo Prático:

Imagine um dataset de saúde com 100 mensagens:

- 90 mensagens sobre agendar\_consulta
- 10 mensagens sobre cancelar\_consulta

Se um modelo for "preguiçoso" e responder **SEMPRE** agendar\_consulta para absolutamente tudo, ele acertará 90 de 100 mensagens. A acurácia dele será de **90%**, mas ele será **100% inútil** para quem precisa cancelar uma consulta!

Para resolver isso, avaliamos o modelo usando **Precision**, **Recall** e **F1-Score**:

| Métrica                        | Pergunta que ela responde                                                                   | Exemplo do Chatbot                                                     |
|--------------------------------|---------------------------------------------------------------------------------------------|------------------------------------------------------------------------|
| <b>Precision</b><br>(Precisão) | Das vezes em que o bot previu a intenção X, quantas vezes ele realmente acertou?            | Evita falsos alarmes. Mede a taxa de acerto quando o bot se posiciona. |
| <b>Recall</b><br>(Revogação)   | De todas as mensagens reais que pertenciam à intenção X, quantas o bot conseguiu encontrar? | Evita a perda de chamados. Mede a capacidade de cobertura do bot.      |
| <b>F1-Score</b>                | Qual é a média harmônica (equilíbrio) entre Precision e Recall?                             | É o indicador principal para decidir se a classe está madura ou não.   |

## Matriz de Confusão

A Matriz de Confusão é uma tabela cruzada entre o que o modelo **previu** e o que era a **classe real**.

| CLASSE REAL | PREDIÇÃO DO MODELO |          |                                     |
|-------------|--------------------|----------|-------------------------------------|
|             | Agendar            | Cancelar |                                     |
| Agendar     | 88                 | 2        | <-- 88 acertos (Diagonal Principal) |
| Cancelar    | 7                  | 3        | <-- 7 erros de confusão             |

- **Diagonal Principal:** Representa os acertos absolutos do modelo.
- **Fora da Diagonal:** Indica onde o modelo está "se confundindo" (ex: 7 mensagens de cancelamento que o bot achou que eram agendamento).

## Scikit-Learn Pipeline: Organização Profissional

Até o momento fizemos a vetorização (`vectorizer.fit_transform`) e o treinamento do modelo (`modelo.fit`) em passos manuais separados.

No universo corporativo real, utilizamos o **Pipeline**. Ele funciona como uma esteira de montagem que empacota o pré-processamento e o algoritmo em um único objeto:

## CÓDIGO EXEMPLO

# Encapsulando o pré-processamento e a classificação na mesma esteira

```
pipeline = Pipeline([  
    ('vectorizer', TfidfVectorizer(stop_words=stopwords_pt)),  
    ('classifier', LogisticRegression())  
])
```

# Treino e predição diretamente no texto bruto!

```
pipeline.fit(X_train, y_train)  
predicoes = pipeline.predict(X_test)
```

### Principais Vantagens do Pipeline:

1. **Sem vazamento de dados:** O pré-processamento e a vetorização do teste são ajustados estritamente na hora certa.
2. **Código limpo:** O modelo em produção recebe a frase em texto puro e já devolve a intenção final sem necessidade de criar variáveis intermediárias.